


9. Predykcja profilu ADMET z wykorzystaniem multi-task learning

Marcin Sztukowski

Jakub Poznanski


Michał Kopczewski



Predykcja profilu ADMET z Multi-Task Learning

ADMET Analysis

Science
Info 





CO TO ADMET-PROPERTIES?

ADMET = Absorption, Distribution, Metabolism, Excretion, Toxicity

Zestaw właściwości farmakokinetycznych i toksykologicznych

Określa zachowanie leku w organizmie

Krytyczne w projektowaniu leków (drug discovery)

Przykłady:

- **Absorption** → wchłanianie (np. HIA)
- **Distribution** → dystrybucja (np. BBB)
- **Metabolism** → metabolizm (np. CYP450)
- **Excretion** → wydalanie
- **Toxicity** → toksyczność (np. hERG, DILI)

Dlaczego skupiamy się na ADMET?

- Wysoki koszt niepowodzeń w późnych fazach badań
- ADMET jest główną przyczyną odrzucania kandydatów na leki
- Wczesna predykcja → oszczędność czasu i kosztów
- Ograniczenie testów in vitro / in vivo
- Przyspieszenie pipeline'u drug discovery

Problem związany z ADMET

Dane często ADMET są:

- rozproszone (różne datasety)
 - niepełne (dużo braków etykiet)
 - niezbalansowane
-
- Każdy task ma inne dane i split
 - Raw features (RDKit, Morgan) nie separują klas
 - Trudne modelowanie pojedynczych tasków (STL)

Pomysł projektu

- Multi-Task Learning (MTL) dla wielu właściwości ADMET
- Jeden model → wiele tasków jednocześnie
- Wspólny encoder (GNN) + osobne głowice
- Wykorzystanie wspólnych wzorców chemicznych

Dataset (TDC ADMET)

- Dataset pochodzi z biblioteki TDC, która agreguje dane biologiczne z różnych eksperymentów farmaceutycznych. Każdy rekord to cząsteczka reprezentowana jako SMILES oraz etykiety dla różnych właściwości ADMET.

Endpointy odpowiadają realnym testom biologicznym, które są wykonywane w procesie projektowania leków.

Struktura datasetu

Nasz Dataset typu ADMET można podzielić na 3 grupy:

- Metabolizm (CYP)
- Transport i bariery
- Toksyczność

Taski są częściowo powiązane, reprezentują różne procesy biologiczne czasami zależne od siebie

Problemy w łączeniu endpointów

1. Splity

- train / valid / test
- zachowane per-task

Każdy task ma własny podział na zbiory, możliwy data leakage podczas trenowania. Czasteczka w jednym tasku jest jako treningowa a w drugim jest jako validate albo test

2. Sparsity danych

Nie każda czasteczka występuje w każdym datasetcie czy tasku

Problemem to brak etykiet dlatego stosujemy mask w funkcji straty.

3. Balans klas oraz pokrycie taskow

Klasy są często niezbalansowane i istnieje mało pokrycia per task

1. PROBLEM SPLITS

- **SPLIT SIZES**

Train: 18898

Valid: 5863

Test : 10123

- **DATA LEAKAGE CHECK**

Train n Val: 0

Train n Test: 0

Val n Test: 0

2. PROBLEM DATA SPARSITY

LABEL SPARSITY

cyp2c19_veith	missing: 10031/18898	sparsity: 0.531
cyp2d6_veith	missing: 9707/18898	sparsity: 0.514
cyp3a4_veith	missing: 10268/18898	sparsity: 0.543
cyp1a2_veith	missing: 10092/18898	sparsity: 0.534
cyp2c9_veith	missing: 10432/18898	sparsity: 0.552
hia_hou	missing: 18491/18898	sparsity: 0.978
pgp_broccatelli	missing: 18045/18898	sparsity: 0.955
bbb_martins	missing: 17477/18898	sparsity: 0.925
herg	missing: 18438/18898	sparsity: 0.976
dili	missing: 18565/18898	sparsity: 0.982

3. CLASS BALANCE AND TASK COVERAGE


CLASS BALANCE


cyp2c19_veith	0: 4804	1: 4063
cyp2d6_veith	0: 7425	1: 1766
cyp3a4_veith	0: 5053	1: 3577
cyp1a2_veith	0: 4746	1: 4060
cyp2c9_veith	0: 5653	1: 2813
hia_hou	0: 53	1: 354
pgp_broccatelli	0: 392	1: 461
bbb_martins	0: 325	1: 1096
herg	0: 149	1: 311
dili	0: 171	1: 162

TASK COVERAGE

Avg labels per sample: 2.5/10

Macierz obecności etykiet (Białe = Brak danych)





Wnioski z obserwacji problemów danych

- Brak globalnego splitu po SMILES → ryzyko leakage między taskami
- Wysoka sparsity → większość próbek ma niepełne etykiety
- Niskie pokrycie tasków per próbka → mało wspólnych przykładów
- Silny class imbalance → bias w kierunku klasy dominującej


TSNE dla związków chemicznych

1 = active → ma daną właściwość (pozytywna klasa dla danego taska)

0 = inactive → nie ma tej właściwości

jeśli dwa punkty są blisko: → podobne molekuły (wg cech)

brak separacji między klasami – potrzeba jakiegoś modelu MTL



Morgan

punkt = wektor 1024
bitów (fingerprint)

interpretacja:

bit = 1 → fragment

struktury istnieje


bit = 0 → brak fragmentu

czyli:

punkt = reprezentacja

struktury molekuły

t-SNE RDKit



RDKit


punkt = wektor ~200
deskryptorów

np.:

masa
logP
liczba wiązań
TPSA
itd.

czyli:

punkt =
fizykochemiczny opis
molekuły



- Wykres przedstawia **projekcję t-SNE embeddingów wyuczonych przez model GNN**
- Każdy punkt odpowiada jednej cząsteczce chemicznej
- Embeddingi zostały wygenerowane przez backbone GIN po agregacji grafu

Obserwacje z Embeddingow GIN w TSNE

- **Embedding GNN częściowo separuje klasy** → lepszy niż Morgan/RDKit
- **Widoczna lokalna struktura** → istnieją regiony wzbogacone w class 1
- **Model nauczył się pewnych wzorców**, ale nie pełnej separacji
- Rozkład nie jest losowy → GNN wydobywa informację taskową
- Brak wyraźnych klastrów → ograniczona zdolność rozróżniania
- Perferyjne klastry → bardziej jednoznaczne przypadki
- **Embedding jest bardziej strukturalny niż raw features**

Dlaczego MTL się sprawdzi dla tych danych?

- Wspólny encoder (backbone) uczy reprezentacji z wielu tasków
- Transfer wiedzy między taskami → poprawa dla małych i rzadkich zbiorów
- Regularizacja przez współdzielenie parametrów → mniejsze overfitting
- Lepsza generalizacja przy nierównowadze klas
- GNN backbone uczy reprezentacji task-aware → separacja active vs inactive
- Korelacje biologiczne między taskami są wykorzystywane w uczeniu
- Jedna przestrzeń embeddingów → spójna reprezentacja molekuł

Klaster 1: Metabolizm (CYP)

To **enzymy** z rodziny cytochromu P450 odpowiedzialne za metabolizm leków w wątrobie.

- decydują jak szybko lek jest rozkładany
- mają podobne mechanizmy działania

ENDPOINTS :

- cyp2c19
- cyp2d6
- cyp3a4
- cyp1a2
- cyp2c9

Klaster 1: Metabolizm (CYP)

- wysoka korelacja między taskami
- podobne cechy strukturalne ligandów
- wspólna przestrzeń feature space

Dlatego ten klaster jest idealny dla multi-task learning bo model może uczyć się wspólnych wzorców

Klaster 2: Transport i bariery

Te **taski** opisują zdolność cząsteczki do przemieszczania się w organizmie.

ENDPOINTS

- **HIA** — wchłanianie jelitowe, czyli czy lek się wchłonie
- **P-gp** — transporter (efflux), czyli czy zostanie wypompowany z komórki
- **BBB** — bariera krew–mózg, czyli czy dotrze do mózgu

Klaster 3: Toksyczność

- **hERG** — kardiotoksyczność , czyli ryzyko arytmii
- **DILI** — hepatotoksyczność, czyli uszkodzenie wątroby

Występują **zależności** z innymi taskami:

- Toksyczność silnie zależna od metabolizmu
- Toksyczność powiązana z akumulacją leku

Czym jest korelacja między zadaniami?

Korelacja mierzy podobieństwo endpointów

Zakres:

$$\rho \in [-1, 1]$$

Interpretacja:

- $\rho > 0 \rightarrow$ podobne mechanizmy biologiczne
- $\rho \approx 0 \rightarrow$ brak związku
- $\rho < 0 \rightarrow$ przeciwne zależności


Korelacja - co dokładnie robimy?

0. wejście: macierz etykiet $Y \in \mathbb{R}^{N \times T}$
1. łączysz datasety po SMILES
2. robisz **outer join** wynikiem jest dużo NaN
3. liczysz korelację tylko na dostępnych parach (**Pearson**)

Co oznacza korelacja w tym projekcie?

- **wysoka korelacja** → podobne zachowanie biologiczne
- **niska korelacja** → brak związku
- **ujemna** → przeciwne efekty

Dla nas : **Jeśli dwa taski są skorelowane, model może wykorzystać wspólną reprezentację i lepiej się nauczyć wzorców**



**Macierz korelacji
pokazuje zależności
między zadaniami
predykcyjnymi.**

Najważniejsze zależności - CYP

metabolizm (CYP)

- $\rho(\text{cyp2c19}, \text{cyp2c9}) = 0.71$
- $\rho(\text{cyp2c19}, \text{cyp3a4}) = 0.50$

To pokazuje, że enzymy metabolizujące są silnie powiązane.

Najważniejsze zależności - **Transport i metabolizm**

- $\rho(\text{pgp}, \text{cyp2c19}) = 0.42$

Transport i metabolizm są powiązane to naturalne biologicznie

Najważniejsze zależności - **Toksyczność**

- $\rho(\text{cyp2d6}, \text{herg}) = 0.53$
- $\rho(c, \text{yp1a2dili}) = 0.50$

Toksyczność zależy od metabolizmu

Słabe zależności

- $\rho(\text{hia}, \text{CYP}) \approx 0$

Nie wszystkie taski są powiązane to ogranicza zdolności MTL.

Najważniejsza ujemna korelacja

- $\rho(\text{pgp}, \text{dili}) = -0.50$

P-gp usuwa cząsteczki **CZYLI** zmniejsza toksyczność
DLATEGO korelacja jest ujemna.

Co Korelacja oznacza dla modelu MTL ?

- **wysoka korelacja → MTL pomaga**
- **brak korelacji → brak efektu**
- **ujemna → możliwy konflikt**

Problem ujemnej korelacji w MTL

$$\rho_{ij} < 0$$

Oznacza, że wzrost jednej właściwości to spadek drugiej
Niektóre endpointy ADMET są biologicznie przeciwstawne.

- Model optymalizuje:

$$\mathcal{L} = \mathcal{L}_i + \mathcal{L}_j$$

- gradient:

$$\nabla \mathcal{L} = \nabla \mathcal{L}_i + \nabla \mathcal{L}_j$$

Jeśli zadania są sprzeczne, ich gradienty wskazują różne kierunki.

Możliwe rozwiązania ujemnej korelacji

- **1. Gradient surgery (PCGrad)**

- $$g_i := g_i - \frac{g_i \cdot g_j}{\|g_j\|^2} g_j$$

2. Task weighting

- $\lambda_i \neq \lambda_j$

Nadanie uczonych wag dla poszczególnych endpointow

To nam daje istotność danego tasku w liczeniu ogólnego LOSS

3. Task grouping

- osobne heady / albo cale modele dla tylko dla dodatnio skorelowanych taskow , nie dopuszczamy do sytuacji gdzie mamy silnie ujemna korelacje

PCGRAD

PCGrad działa w następujący sposób:

- **Detekcja konfliktu:** Sprawdza, czy gradienty dwóch zadań są ze sobą sprzeczne, mierząc ich podobieństwo cosinusowe
- **Projekcja (Surgery):** Jeśli wykryto konflikt, gradient jednego zadania jest rzutowany (projektowany) na płaszczyznę prostopadłą do gradientu drugiego zadania.
- **Eliminacja konfliktu:** Dzięki temu usuwana jest ta część gradientu, która powoduje destrukcyjne interferencje między zadaniami

Schemat modelu

- SMILES przekształcamy na graf — G
- Deskryptory oraz cechy dodatkowe do modelu - x

$$\begin{aligned}h_g &= f_{GIN}(G) \\h_v &= f_{MLP}(x) \\h &= [h_g \parallel h_v] \\y_t &= f_t(h)\end{aligned}$$

- Dwie ścieżki przetwarzania są łączone w jeden embedding, który trafia do wielu głowic.

Dlaczego GNN?

- Molekuła to graf (atomy + wiązania)
- GNN uczy reprezentacji struktury chemicznej
- Lepsze niż ręczne cechy (Morgan, RDKit)
- Embedding dostosowany do tasków (task-aware)

Reprezentacja czasteczki

Każdy atom ma wektor: $x_v \in \mathbb{R}^9$

Cechy:

- liczba atomowa
- stopień (degree)
- ładunek formalny
- aromatyczność
- wartościowość
- hybrydyzacja
- elektrony rodnikowe
- masa (skalowana)
- czy w pierścieniu

Każda cząsteczka jest zamieniana na graf

$G=(V,E)$ V — atomy

E — wiązania

Krawędzie (wiązania)

edge_index $\in \mathbb{R}^2 \times |E|$

graf nieskierowany ma
krawędzie w obie strony

$$h_v^{(k)} = \text{MLP}^{(k)} \left((1 + \epsilon) h_v^{(k-1)} + \sum_{u \in \mathcal{N}(v)} h_u^{(k-1)} \right)$$

Noga grafowa (GIN)

GIN agreguje informacje z sąsiednich atomów i buduje reprezentację całej cząsteczki.

Cechy wszystkich atomów sąsiadnych są sumowane, aby uzyskać jeden wektor opisujący całą cząsteczkę.

WZOR GIN :
$$h_v^{(k)} = \text{MLP}^{(k)} \left((1 + \epsilon) h_v^{(k-1)} + \sum_{u \in \mathcal{N}(v)} h_u^{(k-1)} \right)$$

- $h_v^{(k)}$ — reprezentacja atomu v po k -tej warstwie
- $h_v^{(k-1)}$ — cechy atomu z poprzedniej warstwy
- $\mathcal{N}(v)$ — zbiór sąsiadów atomu
- $\sum_{u \in \mathcal{N}(v)} h_u$ — agregacja sumowaniem informacji z sąsiadów
- ϵ — waga informacji własnej atomu
- MLP — nieliniowa transformacja

Dlaczego suma?

Nowa reprezentacja atomu to suma jego własnych cech oraz cech jego sąsiadów.

Suma :

- **zachowuje informację o liczbie sąsiadów**
- **rozdóżnia różne struktury**

Średnia jako pooling by zgubiła informacje, a suma zachowuje strukturę chemiczną.

Noga wektorowa (MLP)

$$h_v = f_{MLP}(x)$$

- Morgan fingerprints
- deskryptory RDKit

MLP przetwarza globalne właściwości cząsteczki, których graf nie oddaje bezpośrednio.

$$h = \text{Concat}(h_g, h_v)$$

Łączymy reprezentację grafową i wektorową w jeden embedding.

Multi-Head (MTL)

- Dla każdego endpointu / tasku tworzymy MLP

$$y_t = f_t(h)$$

jedna głowica = jeden task

wspólny backbone całego modelu

Model przewiduje wiele właściwości jednocześnie, korzystając ze wspólnej reprezentacji.

Funkcja straty

Funkcja straty :

- $\mathcal{L} = \sum_{t=1}^T \lambda_t \mathcal{L}_t$
- $\mathcal{L}_t = BCE(y_t, \hat{y}_t) \cdot \mathbb{1}_{y_t \neq NaN}$

Liczymy poszczególne wartości straty dla każdego endpointu i sumujemy je

Strata jest liczona tylko dla dostępnych etykiet (maskowanie NaN).

Hipotezy badawcze

- 1.** Model multi-task osiąga lepszą średnią jakość predykcji (AUROC dla klasyfikacji, RMSE dla regresji) niż analogiczne modele single-task, szczególnie dla endpointów z małą liczbą danych treningowych.
- 2.** Endpointy ADMET, które są ze sobą biologicznie powiązane (np. rozpuszczalność i Caco-2 permeability), korzystają z multi-task learning bardziej niż endpointy niepowiązane.
- 3.** Reprezentacje molekularne (fingerprinty vs. deskryptory vs. wyuczone embeddingi) mają istotny wpływ na jakość predykcji ADMET. Porównanie co najmniej dwóch typów reprezentacji.

1. Multi-Task Learning (MTL) vs Single-Task Learning (STL)

- zadania ADMET są powiązane
- model współdzieli reprezentację
- następuje **transfer wiedzy**

Definicja modeli

- **STL:**

$$y_t = f_t(x)$$

- **MTL:**

$$y_t = f_t \left(h_{shared}(x) \right)$$

METRYKI

Metryka (AUROC)

$$AUROC = P(\hat{y}_{pos} > \hat{y}_{neg})$$



- $\rightarrow 0.5$ losowo
- $1.0 \rightarrow$ idealnie

Gain z MTL


$$\Delta_t = AUROC_{MTL,t} - AUROC_{STL,t}$$


- $\Delta_t > 0 \rightarrow$ MTL lepszy
- $\Delta_t < 0 \rightarrow$ MTL gorszy

TRENING SAMEGO GNN - LOSS



POROWNANIE MTL VS STL VS XGBOOST (tylko graf)







MTL wykorzystuje wspólną strukturę danych, co prowadzi do lepszej generalizacji niż STL

SKUTECZNOSC SAMEGO GIN


W **endpointach** (np. hERG, DILI):


- cechy wektorowe nie są spójne z reprezentacją grafową
- model uczy się sprzecznych zależności
- MTL zaczyna szkodzić zamiast pomagać

TRENING GNN + RDKIT + MORGAN - LOSS



POROWNANIE MTL VS STL (graf + rdkit + morgan)





SKUTECZNOŚĆ GIN + MORGAN + RDKit

Model osiąga wysoki gain dla większości endpointów.
Największe zyski w zadaniach powiązanych (CYP, BBB).
Jednocześnie pojawiają się małe spadki (hERG, DILI).

Wnioski

- więcej cech to nie zawsze znaczy lepiej
jeśli cechy są słabo powiązane z taskiem → degradacja wyniku
- **Duża liczba cech to większe ryzyko negative transfer oraz szumu**

2. czy korelacja daje zysk MTL

1. Oś X – średnia korelacja

$$\rho_t = \frac{1}{T-1} \sum_{j \neq t} \rho_{tj}$$

→ jak bardzo dany task jest **powiązany z innymi**


2. Oś Y – gain z MTL

$$\Delta_t = AUROC_{MTL,t} - AUROC_{STL,t}$$

→ ile **zyskałeś dzięki multi-task learning**

WYKRESY KORELACJA VS MTL GAIN

1. WYKRES DLA SIECI HYBRYDOWEJ GNN + RDKit + MORGAN
2. WYKRES DLA SAMEGO GNN




Trend

linia regresji: **wyraźnie rosnąca**

im większa korelacja $\rho_t \rightarrow$ tym większy gain Δ_t

- prawa strona $\rightarrow$ dodatni gain
- lewa strona $\rightarrow$ ujemny gain

Dodanie deskryptorów stabilizuje i wzmacnia efekt MTL.



Zysk z MTL rośnie wraz z korelacją zadań, ale efekt jest ograniczony i nie obejmuje wszystkich endpointów

Wniosek

Wyniki pokazują silną **dodatnią zależność** między **korelacją zadań** a **zyskiem z multi-task learning**.

Taski metaboliczne, które są biologicznie powiązane, znacząco korzystają z MTL, podczas gdy zadania toksykologiczne wykazują spadek wydajności ze względu na konflikty gradientów.”

- Dla złych tasków i oraz j :


$$\nabla L_i \cdot \nabla L_j < 0$$

Intepretacja wpływu typu wejść na wynik AUROC

Graf sam daje najlepszy wynik (~ 0.904), a dodanie RDKit i Morgan nie poprawia go istotnie.

Same deskryptory (szczególnie RDKit) są wyraźnie słabsze , a sam graf niesie kluczową informację.

Porównanie 6 kombinacji reprezentacji molekularnych (MTL)



MTL VS STL DLA INNEGO DATASETU

- **# --- ADME Classification ---**

'hia_hou', # Wchłanianie jelitowe

'pgp_broccatelli', # P-glikoproteina (transporter)

'bbb_martins', # Bariera krew-mózg

'cyp2c19_veith', # Metabolizm (enzymy)

'cyp2d6_veith',

'cyp3a4_veith',

'cyp1a2_veith',

'cyp2c9_veith',

--- Toxicity Classification ---

'herg', # Kardi toksyczność

'dili', # Toksyczność wątroby

'skin_reaction', # Reakcje skórne

'ames', # Mutagenność

'clintox' # Toksyczność kliniczna

Quick Data Stats

SPLIT SIZES

- Train: 24799
- Valid: 6755
- Test : 11880


DATA LEAKAGE CHECK


- Train n Val: 0
- Train n Test: 0
- Val n Test: 0

TASK COVERAGE


- Avg labels per sample: 2.17/13

Data sparsity dla 13 endpoints





Korelacje między endpointami



Korelacje biologiczne

silne korelacje w CYP (metabolizm):

- $\text{cyp2c19} \leftrightarrow \text{cyp2c9}$ (≈ 0.7)
 - $\text{cyp3a4} \leftrightarrow$ inne CYP
- wspólny mechanizm enzymatyczny

transport / dystrybucja:

- $\text{pgp} \leftrightarrow \text{bbb}$ (umiarkowane)

toksyczność:

- herg, dili → słabe / mieszane korelacje

skin_reaction:

- bardzo wysokie korelacje (artefakt / dane)

HIPOTEZY BADAWCZE NA TYM PRZYKŁADZIE


- 1. MTL VS STL GAIN**
- 2. POWIAZANIE KORELACJI Z MTL GAIN**
- 3. POROWNANIE TYPU WEJSC NA MTL AUROC**

1. MTL VS STL GAIN


WYKRESY DLA KOMBINACJI CECH NA WEJSCIU

- **1. GNN**
- **2. GNN + MORGAN**
- **3. GNN + RDKIT**
- **4. GNN + MORGAN + RDKIT**


1. GNN



2. GNN + MORGAN




3. GNN + RDKIT



4. GNN + MORGAN + RDKIT

Gain from MTL



WYNIKI DLA RDKit + Morgan + GNN


Interpretacja

- dodanie **RDKit + Morgan + GNN**:
 - poprawia wyniki dla większości tasków
 - szczególnie dla:
 - skin_reaction (bardzo duży gain)
 - cyp2c9, cyp2d6, cyp2c19
 - pgp_broccatelli, dili

Tylko pojedyncze przypadki mają **negative transfer**
więcej cech zwykle pomaga (lepszą reprezentacją)

2. POWIAZANIE KORELACJI Z MTL GAIN

1. Korelacja vs MTL gain dla samego GNN



Korelacja vs MTL gain dla samego GNN


Model pokazuje słabą zależność między korelacją a zyskiem z MTL.

Punkty są mocno rozproszone, co oznacza niestabilny transfer wiedzy.

Dla części zadań (hERG, DILI, Clintox) obserwujemy spadek jakości. Model nie wykorzystuje dobrze korelacji między zadaniami.

Powód: brak globalnych cech → tylko lokalna struktura grafu

2. Korelacja vs MTL gain GNN + cechy



Korelacja vs MTL gain GNN + cechy

Widoczna jest wyraźna dodatnia zależność:

większa korelacja → większy zysk.

Punkty są bardziej uporządkowane względem linii trendu.


Większość zadań ma dodatni gain (MTL działa poprawnie).

Negatywny transfer jest dużo mniejszy.

Powód: bogatsza reprezentacja (struktura + właściwości + fragmenty).

3. POROWNANIE TYPU WEJSC NA MTL AUROC

Porównanie 6 kombinacji reprezentacji molekularnych (MTL)



Obserwacje

- Najlepszy wynik: **G1_R1_M1 (0.8868)** → połączenie grafu + RDKit + Morgan daje najwyższą jakość
- Sam graf (**G1_R0_M0 = 0.8826**) jest już bardzo silny
- Dodanie pojedynczych cech (RDKit lub Morgan) daje niewielką poprawę
- Brak grafu (**G0_***): wyraźny spadek jakości
- Najgorszy wynik: **tylko RDKit (0.7456)**

Wniosek:

Graf jest kluczowy, a deskryptory (RDKit, Morgan) działają jako uzupełnienie, nie zamiennik.

Najważniejsze obserwacje z projektu

- **Cechy typu (RDKit, Morgan) nie separują dobrze klas**
- Embeddingi z GNN pokazują częściową separację → model uczy się sensownych reprezentacji
- MTL pomaga szczególnie przy zadaniach z małą ilością danych
- **Model uczy się wspólnych wzorców chemicznych między taskami**
- **Korelacja między zadaniami pomaga w transferze wiedzy**

Wnioski z projektu

- MTL jest bardziej odpowiedni dla problemów ADMET niż podejście single-task
- GNN daje lepszą reprezentację struktury chemicznej niż ręczne deskryptory
- Wspólne uczenie wielu właściwości poprawia generalizację

Model MTL oparty na GNN uczy wspólną reprezentację molekuł, co pozwala lepiej przewidywać właściwości ADMET mimo trudnych, niekompletnych danych.

Uwagi do projektu -XGBoost

- **XGBoost** osiąga bardzo zbliżone wyniki AUROC dla większości zadań
- **XGBoost** stanowi silny punkt odniesienia i w wielu przypadkach jest wystarczający
- Złożone modele (GNN, MTL) mają sens głównie przy większych danych lub gdy chcemy uczyć reprezentacji grafowych związków

XGBoost zapewnia bardzo wysoką skuteczność przy minimalnej złożoności, co czyni go praktycznym i trudnym do pobicia baseline'em dla problemu ADMET.

Dziękujemy za uwagę!

- Marcin Sztukowski
- Jakub Poznanski
- Michał Kopczewski

