

Predykcja profilu ADMET z wykorzystaniem multi-task learning

Marcin Sztukowski, Michał Kopczewski, Jakub Poznański

1. Repozytorium kodu

Link do repozytorium

https://github.com/FBI223/ADMET_MULTI_TASK_LEARNING#

Deklaracje:

- ☐ Jeżeli repozytorium jest prywatne, to zostało ono udostępnione prowadzącym (nazwa użytkownika: mokosaur).

2. Dane

1) (regresja)

caco2_wang (permability)

solubility_aqsolddb (solubility) -

(wysoka korelacja między tymi taskami)

2) (klasyfikacja) Absorption / Distribution - to jest dobry cluster z wysoka korelacja

- hia_hou

- bioavailability_ma

- bbb_martins

3) (klasyfikacja) METABOLISM / TRANSPORT

- cyp2d6_veith

- cyp3a4_veith

- cyp2c9_veith

- herg_karim

- pgp_broccatelli

4) (klasyfikacja) Metabolism

- cyp2d6_veith
- cyp3a4_veith
- cyp2c9_veith

6) Small Datasets - good MTL gain

- cyp2c9_substrate_carbonmangels
- cyp2d6_substrate_carbonmangels

7) datasets with no MTL gain

- ames
- hia_hou
- cyp2d6_veith

3. Metody

PREPROCESSING DANYCH :

1. reprezentacja molekuł:
 - a. Morgan fingerprint
 - b. Deskryptory RDKit
 - c. Embeddingi (ChemBERTa / MolBERT)
 - d. Embeddingi grafowe (Deepchem / Chemprop)
 - e. Dane kwantowe z programu XTB
 - f.
2. Standaryzacja cech
3. Maskowanie braków, np 0 gdy brakuje cechy fizykochemicznej
4. SMILES -> wyciągnięcie cech -> wektor wejściowy modelu
4. dopasowanie datasetów - inner join po SMILES (overlap cząsteczek)
5. Podział danych -> scaffold split / train-test-val split

MODELE SINGLE TASK – BASELINE

osobny model dla każdego endpointu

- Random Forest
- XGBoost

Model Multi-Task Learning

Multi-Head MLP

1. Architektura : Input $\rightarrow$ shared layers $\rightarrow$ task-specific heads $\rightarrow$ Output

$$h = f_{\text{shared}}(x)$$

$$y_i = f_i(h)$$

2. LOSS

Masked loss (missing labels)

klasyfikacja: BCEWithLogitsLoss - AUROC

regresja: MSELoss – RMSE

3. WAGI

$$\text{Stałe wagi} : L = \sum_i w_i L_i$$

$$\text{Uncertainty weighting} : L = \sum_i (1/\sigma_i^2) L_i + \log \sigma_i$$

CHEMPROP – GOTOWY FRAMEWORK

Architektura (MPNN)

REPREZENTACJA

V (atomy): atom type, degree, formal charge, hybridization

E (wiązania): bond type, aromaticity

DZIAŁANIE

1. model przesyła informacje między atomami przez wiązania
2. każdy atom aktualizuje swoją reprezentację na podstawie sąsiadów
3. po kilku iteracjach powstaje wektor reprezentujący całą cząsteczkę
- 4.

Chemprop przekształca cząsteczkę w graf, uczy jej reprezentacji poprzez message passing między atomami, a następnie wykorzystuje wspólny embedding do predykcji wielu właściwości jednocześnie za pomocą zadaniowo-specyficznych głowic.

Cechy CHEMPROP

- działa “out-of-the-box”
- wbudowany MTL (--multitask)

Eksperymenty

1. **MTL vs Single-task ($\Delta = \text{AUROC_MTL} - \text{AUROC_ST}$)**
2. **Wpływ reprezentacji (Morgan vs RDKit vs Embedding)**
3. **Wpływ korelacji między taskami na skuteczność modelu**
4. **Negative transfer – wpływ nieskorelowanych ze sobą tasków na wynik modelu**
5. **MTL GAIN dla małych datasetów (czy $\text{MTL} > \text{ST}$ przy małych danych ?)**

Problemy

- brakujące etykiety → brak etykiet dla wielu tasków -> maski dla loss
- niezbalansowane klasy → class weights
- różne typy zadań → regresja + klasyfikacja -> różne funkcje straty
- małe datasety → overfitting
- brak overlap między datasetami - słaby transfer między taskami
- różne rozkłady danych
- leakage - podobne molekuły w train/test - scaffold split
- różna jakość reprezentacji molekuł
- Negative transfer - MTL może pogorszyć wyniki – wybranie skorelowanych tasków
- Interpretacja działania modelu - trudno wyjaśnić decyzje modelu typu GNN / MTL